

# 基于注意力机制的堆叠 LSTM 网络雷达 HRRP 序列目标识别方法

张一凡<sup>1,\*</sup>, 张双辉<sup>2</sup>, 刘永祥<sup>2</sup>, 荆 锋<sup>1</sup>

(1. 国防科技大学信息通信学院, 陕西 西安 710106;

2. 国防科技大学电子科学学院, 湖南 长沙 410073)

**摘 要:** 传统的雷达高分辨距离像(high resolution range profile, HRRP)序列识别方法依赖于人工特征提取,并且现有的深度学习方法存在梯度消失问题,导致收敛速度慢,识别精度低。针对上述问题,提出一种基于注意力机制的堆叠长短时记忆(attention-based stacked long short-term memory, Attention-SLSTM)网络模型,该模型通过堆叠多个长短时记忆(long short-term memory, LSTM)网络层,实现了 HRRP 序列更深层次抽象特征的提取;通过替换模型的激活函数,减缓了堆叠 LSTM(stacked LSTM, SLSTM)模型梯度消失问题;引入注意力机制计算特征序列的分配权重并用于分类识别步骤,增强了隐藏层特征的非线性表达能力。模型在雷达目标识别标准数据集 MSTAR 上多种不同目的的实验结果表明,所提方法具有更快的收敛速度和更好的识别性能,与多种现有方法对比具有更高的识别率,证明了所提方法的正确性和有效性。

**关键词:** 高分辨距离像序列;注意力机制;长短时记忆网络;雷达目标识别

**中图分类号:** TN 95

**文献标志码:** A

**DOI:**10.12305/j.issn.1001-506X.2021.10.09

## Radar HRRP sequence target recognition method of attention mechanism based stacked LSTM network

ZHANG Yifan<sup>1,\*</sup>, ZHANG Shuanghui<sup>2</sup>, LIU Yongxiang<sup>2</sup>, JING Feng<sup>1</sup>

(1. School of Information and Communication, National University of Defense Technology, Xi'an 710106, China;

2. School of Electronic Science and Technology, National University of Defense Technology, Changsha 410073, China)

**Abstract:** The traditional radar high resolution range profile (HRRP) sequence recognition method relies on artificial feature extraction, and the existing deep learning method has the problem of gradient vanishing, which leads to the slow convergence speed and low recognition accuracy of the existing recognition methods. To solve these problems, an attention-based stacked long short-term memory (Attention-SLSTM) network model is proposed, which realizes the extraction of deeper abstract features of HRRP sequence by stacking multiple long short-term memory (LSTM) network layers. By replacing the activation function of the model, it slows down the gradient vanishing problem of stacked LSTM. The attention mechanism is introduced to calculate the distribution weight of feature sequence and use it in the classification and recognition step, which enhances the nonlinear expression ability of hidden layer features. Experimental results on the radar target recognition standard data set MSTAR for different purposes show that the proposed method has faster convergence speed and better recognition performance, and has higher recognition rate compared with other existing methods,

收稿日期:2021-02-15;修回日期:2021-04-13;网络优先出版日期:2021-05-28。

网络优先出版地址:https://kns.cnki.net/kcms/detail/11.2422.TN.20210528.1502.016.html

\* 通讯作者。

引用格式:张一凡,张双辉,刘永祥,等.基于注意力机制的堆叠 LSTM 网络雷达 HRRP 序列目标识别方法[J].系统工程与电子技术,2021,43(10):2775-2781.

**Reference format:** ZHANG Y F, ZHANG S H, LIU Y X, et al. Radar HRRP sequence target recognition method of attention mechanism based stacked LSTM[J]. Systems Engineering and Electronics, 2021, 43(10):2775-2781.

which proves the correctness and effectiveness of the proposed method.

**Keywords:** high-resolution range profile sequence (HRRPs); attention mechanism; long short-term memory (LSTM) network; radar automatic target recognition (RATR)

## 0 引言

雷达具有全天时、全天候工作和远距离探测的能力,在导弹防御、空间目标监视中发挥着至关重要的作用<sup>[1]</sup>,因此雷达自动目标识别(radar automatic target recognition, RATR)技术一直是国内外相关领域的研究热点。用于目标识别的雷达数据有 3 种,即合成孔径雷达(synthetic aperture radar, SAR)图像、逆 SAR(inverse SAR, ISAR)图像和高分辨距离像<sup>[2]</sup>(high resolution range profile, HRRP)。由于 SAR/ISAR 图像的获取难度较大,实际中难以获取质量较高的二维图像,同时具有数据量大、运算量大等缺点,而 HRRP 具有成像简单、易于获取、数据量小、运算复杂度低等优势<sup>[3]</sup>,因此 HRRP 自动目标识别技术成为了一种很有应用前景的识别方法。在目标识别场景中,目标的运动轨迹和状态具有连续性,接收机所接收到的 HRRP 序列相邻回波之间存在空间和时间上较强的相关性<sup>[4-5]</sup>,然而传统的 HRRP 识别方法只用到了单个 HRRP 样本,忽略了相邻样本之间的时空相关性,造成信息损失,因此本文将主要研究基于 HRRP 序列的雷达目标识别方法。

根据分类器原理的不同,HRRP 序列识别方法可以大致分为 3 类。第 1 类是基于统计学习算法的识别方法,Du 等人<sup>[6]</sup>利用基于统计特征的识别方法提出了新的目标 HRRP 的特征提取方法;文献<sup>[7]</sup>提出将支撑矢量机(support vector machine, SVM)作为 HRRP 序列识别模型,提高了识别性能,但是此类算法存在识别精度低、收敛速度慢等不足。第 2 类是隐马尔可夫模型(hidden Markov model, HMM),文献<sup>[8]</sup>利用长宽相关 HRRP 序列进行建模,其中跨距离单元的空间结构用 HMM 结构描述,HRRP 样本之间的时间相关性用转移的时间演化描述概率,在一定程度上提高了识别精度。第 3 类方法是基于神经网络算法的识别方法,反向传播(back propagation, BP)网络<sup>[9]</sup>、受限玻尔兹曼机网络<sup>[10]</sup>、自组织神经网络<sup>[11]</sup>等浅层神经网络在 HRRP 识别任务中主要被当作分类器使用;包含多个隐藏层的深层神经网络能够完成特征提取和分类任务,包括深度置信网络<sup>[12]</sup>(deep belief network, DBN)、卷积神经网络<sup>[13-14]</sup>(convolutional neural networks, CNN)和循环神经网络<sup>[15-16]</sup>(recurrent neural networks, RNN),相比于人工特征提取方式,深层网络可以提取到样本中更多深层且可分性强的特征,从而获得更优的识别性能,文献<sup>[16]</sup>使用 RNN 完成了对 3 类目标的 HRRP 样本识别,在 100 个样本的测试集上识别性能良好。然而,经典的 RNN 在训练过程

中容易出现梯度消失和梯度爆炸问题,进而影响模型的训练和识别效果。文献<sup>[17]</sup>使用长短期记忆(long short-term memory, LSTM)网络处理时序数据,LSTM 网络能够有效利用序列数据中的长距离依赖信息,模型解决了梯度消失和梯度爆炸问题,该方法在 HRRP 识别任务上取得了较为理想的识别效果。

为进一步降低模型运算复杂度,将分类模型关注的重点集中在对识别影响较大的特征信息上,文献<sup>[18]</sup>将注意力机制与 RNN 模型相结合,在雷达信号干扰抑制领域进行了探索,该方法有效提升了 RNN 的模型性能,但是模型在针对序列角误差鲁棒性方面还有待提高。文献<sup>[19]</sup>在 LSTM 模型中引入了注意力机制,并用于飞机目标的 HRRP 识别,取得较为理想的识别效果。然而,随着 HRRP 序列长度以及样本容量的增加,传统的单层 LSTM 网络已经无法满足现实任务需求。文献<sup>[20]</sup>使用 3 层堆叠 LSTM(stacked LSTM, SLSTM)达到了更好的识别性能,然而该方法在 LSTM 层数超过 3 层时,会再次出现梯度消失现象,从而导致浅层 LSTM 的权重无法在参数迭代中得到更新,因此本文拟将 LSTM 中传统的激活函数替换为导数性能更优的 Elu 函数,以期缓解 SLSTM 网络中出现的梯度消失问题。

针对目前上述 HRRP 序列目标识别所面临的困难,本文提出一种基于注意力机制的 SLSTM(attention-based SLSTM, Attention-SLSTM)网络模型,模型的**创新点**主要包括以下几点:

- (1) 为了能够提升**单层 LSTM 模型的特征提取能力**,将**SLSTM**模型引入到 HRRP 序列识别任务;
- (2) 为**区别关注多维特征点的 HRRP 序列数据中的重要信息**,将**注意力机制**与 SLSTM 模型相结合,提出 Attention-SLSTM 模型;
- (3) 为缓解 Attention-SLSTM 模型存在的**梯度消失**问题,采用求导性能更好的**Elu**函数替代 Attention-SLSTM 模型中原始的激活函数。

## 1 Attention-SLSTM 模型

### 1.1 Attention-SLSTM 模型结构

本文提出的基于 LSTM 的雷达 HRRP 序列目标识别方法 Attention-SLSTM 模型结构,其框架如图 1 所示,模型分为输入层、特征提取层、注意力层和输出层。

#### (1) 输入层

采用公开的 MSTAR(moving and stationary target acquisition and recognition)数据集作为试验数据进行相关验

证实验,该数据集由 10 种不同类型的 SAR 图像样本构成,本文数据预处理阶段根据文献[21]的方式将二维 SAR 图像转换为不同长度的 HRRP 序列。




图 1 Attention-SLSTM 模型结构示意图

Fig. 1 Structure diagram of Attention-SLSTM model

## (2) 特征提取层

模型采用 SLSTM 作为特征提取器,通过多层 LSTM 结构逐层提取 HRRP 序列的深层可分性特征,较低层提取到基本概念特征,而较高层则关注更加抽象的深层特征。每层输出一个特征向量序列作为后续层的输入,实现 HRRP 序列更有效的特征表示,增强模型的表达能力。在此过程中,为了缓解文献[20]中出现的梯度消失问题,采用求导性能更优的 Elu 函数代替 LSTM 中的原始激活函数,进而促进模型更新迭代,提取更有效的深层抽象特征。

## (3) 注意力机制层

模型在 SLSTM 的每一层输出特征向量后添加注意力机制层<sup>[22-24]</sup>,以前一层 LSTM 的隐藏状态和单元状态作为输入,为隐藏层特征向量的各个区域计算权重,得到的加权 LSTM 隐藏状态能够学习更复杂的抽象特征层级的条件分布,更好地表示不同特征层级间的结构关系,进而**增强特征**的非线性表达能力。

## (4) 输出层

模型利用 Softmax 分类器<sup>[25]</sup>计算  $T$  时刻模型的分类输出结果。输出层的输入为注意力矩阵与 LSTM 所提取的 HRRP 隐层序列特征的乘积,输出为样本类别。

## 1.2 特征提取层

SLSTM 的基本组成结构是 LSTM 单元,是 LSTM 在同一时间步长上的堆叠,LSTM 是一类特殊的 RNN,能够有效避免 RNN 存在的梯度消失和梯度爆炸问题,同时能够

有效提取和利用序列样本中长距离依赖信息,常用于序列数据的处理<sup>[26-28]</sup>。图 2 为 LSTM 模型的结构示意图。




图 2 LSTM 模型结构示意图

Fig. 2 Structure diagram of LSTM model

LSTM 单元通过输入门  $i_t$ 、遗忘门  $f_t$  和输出门  $o_t$  进行状态迭代。其中:

$$i_t = \sigma(W_{ix}x_t + W_{ih}h_{t-1} + b_i) \quad (1)$$

$$f_t = \sigma(W_{fx}x_t + W_{fh}h_{t-1} + b_f) \quad (2)$$

$$o_t = \sigma(W_{ox}x_t + W_{oh}h_{t-1} + b_o) \quad (3)$$

$$c_t = f_t c_{t-1} + i_t \varphi(W_{cx}x_t + W_{ch}h_{t-1} + b_c) \quad (4)$$

$$h_t = o_t \varphi(c_t) \quad (5)$$

式中:  $x_t$  表示当前时刻 LSTM 的输入向量;  $h_{t-1}$ 、 $c_{t-1}$  分别表示  $t-1$  时刻 LSTM 单元的隐藏层状态和单元状态;  $W$  为权重矩阵;  $b$  代表偏置向量;  $\sigma(\cdot)$  为激活函数 sigmoid;  $\varphi$  为 tanh 函数。

在 LSTM 单元中, sigmoid 函数及其导数为

$$\text{sigmoid}(x) = \frac{1}{1 + e^{-x}} \quad (6)$$

$$\text{sigmoid}'(x) = \frac{1}{1 + e^{-x}} \left(1 - \frac{1}{1 + e^{-x}}\right) \quad (7)$$

Sigmoid 函数及导数图像如图 3 所示。




图 3 Sigmoid 函数及其导数图像

Fig. 3 Graph of sigmoid and its derivative

由图(3)可知, sigmoid 函数的导数取值范围为  $(0, 0.25]$ , 当 LSTM 层数增加, 在目标函数多次求导时会导致梯度消失问题的出现, 因此本文采用求导性能较好的 Elu 函数替换 sigmoid 函数作为 SLSTM 模型的激活函数, Elu 函数及其导数分别为

$$\text{Elu}(x) = \begin{cases} \alpha(e^x - 1), & x \leq 0 \\ x, & x > 0 \end{cases} \quad (8)$$

$$\text{Elu}'(x) = \begin{cases} \alpha e^x, & x \leq 0 \\ 1, & x > 0 \end{cases} \quad (9)$$

相对应的函数图像如图 4 所示,由图 4 可知,Elu 函数导数的取值范围为(0,1],可以减缓梯度消失现象的出现。




图 4 Elu 函数及其导数图像

Fig. 4 Graph of Elu and its derivative

### 1.3 注意力机制层

将 Attention-SLSTM 模型的注意力机制层展开如图 5 所示。

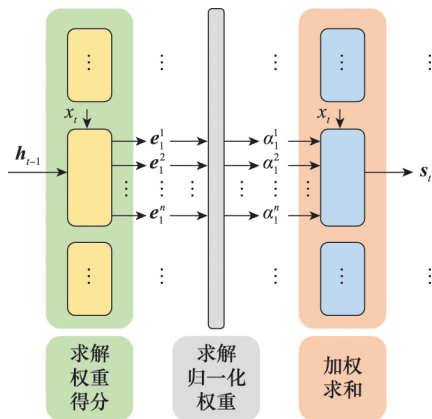


图 5 本文注意力机制结构图

Fig. 5 Structure of attention mechanism in this paper

注意力机制参数学习可分为 3 个步骤<sup>[29]</sup>。

**步骤 1** 求解权重得分,权重即特征向量对模型识别的贡献大小,其计算方法为

$$e' = v^T \cdot \tanh(W_a \cdot X_t + b) \quad (10)$$

**步骤 2** 求解归一化权重,即加权系数:

$$\alpha' = \frac{\exp(e'_j)}{\sum_{j=1}^T \exp(e'_j)} \quad (11)$$

**步骤 3** 加权求和:

$$s' = \sum_{j=1}^T \alpha'_j X_{t,j} \quad (12)$$

在式(10)~式(12)中, $v^T$ 和 $b$ 均为超参数, $W_a$ 为注意力矩阵,需要随机初始化设置, $X_t$ 为输入向量,维度为 $n \times r$ , $n$ 表示模型批处理的样本数, $r$ 为 LSTM 隐藏层神经元个数,输入向量为 LSTM 的隐藏层状态 $H_t$ 或单元状态 $C_t$ ,即

$$H_t = (h_t^{(1)}, h_t^{(2)}, \dots, h_t^{(r)}) \quad (13)$$

$$C_t = (c_t^{(1)}, c_t^{(2)}, \dots, c_t^{(r)}) \quad (14)$$

式中: $h_t^{(l)}$ 和 $c_t^{(l)}$ 分别代表在第 $t$ 个时间步上第 $l$ 层 LSTM 单元的隐藏层状态以及单元状态。

### 1.4 输出层

在得到 SLSTM 模型隐层序列特征 $H_t$ 之后,采用 softmax 分类器输出样本的类别:

$$p(y_{ij} | X, \theta) = \frac{\exp(w_j h_t)}{\sum_j \exp(w_j h_t)} \quad (15)$$

式中: $p(y_{ij} | X, \theta)$ 表示样本序列属于第 $j$ 类的概率值; $w_j \in \mathbf{R}^{1 \times m}$ 为分类器中的权值矩阵中的元素; $m$ 为隐层单元数。模型最终识别类别为所有 $j$ 类概率值最大的类别。

## 2 实验结果与分析

### 2.1 MSTAR 数据集

MSTAR 数据集<sup>[30-31]</sup>是 SAR 目标识别的标准数据集,其数据来源于分辨率为 $0.3 \text{ m} \times 0.3 \text{ m}$ 的 SAR,雷达在 X 波段工作,并且采用 HH 极化方式。MSTAR 数据集中包含 BTR70 装甲运输车、BMP2 步兵战车和 T72 坦克等 10 种不同类别的地面样本,其光学图像和对应的 SAR 图像样本如图 6 所示。数据集中的训练数据来自雷达工作俯仰角为 $17^\circ$ 时所得到的目标图像数据,而测试集数据的俯仰角为 $15^\circ$ ,以便于检验模型的泛化性能。




图 6 MSTAR 数据集光学图像及对应的 SAR 图像样本

Fig. 6 Optical and corresponding SAR image in MSTAR dataset



表 1 MSTAR 序列 HRRP 数据集的组成

Table 1 Content of MSTAR HRRP sequence dataset 个

类别	训练集(17°)	测试集(15°)
BMP2(SN-9566)	2 330	1 960
BTR70(SN-C71)	2 330	1 960
T72(SN-132)	2 320	1 960
BTR60	2 560	1 950
2S1	2 990	2 740
BRDM2	2 980	2 740
D7	2 990	2 740
T62	2 990	2 730
ZIL131	2 990	2 740
ZSU23/4	2 990	2 740
合计	27 470	32 030

本文实验将每幅 SAR 图像按照文献[19]的方法变换为 HRRP 序列。步骤为首先 SAR 图像做一维逆快速傅里叶变换(fast Fourier transform, FFT)变换得到复数域 HRRP 序列,再对其取幅度值并求平均得到平均 HRRP 序列。在此过程中,每幅 SAR 图像能够得到 100 幅 HRRP 样本,再将其转换成 10 幅平均 HRRP。由于原始 MSTAR 数据集中包含 2 747 个 SAR 图像训练样本和 3 203 个测试样本,因此可以得到 27 470 个 HRRP 序列训练样本和 32 030 个测试样本,表 1 给出了该数据集的组成。

## 2.2 实验结果与分析

为验证本文所提出方法在 HRRP 序列识别种的有效性,设计了两类不同目的对比实验,分别检验本文 SLSTM 和注意力机制的有效性。设置了多种传统机器学习方法和深度学习作为基线方法开展对比实验,包括 SVM、RNN、LSTM、SLSTM 和 Attention-RNN。为了消除实验中随机误差对结果带来的影响,每种实验方法均在相同参数设置的条件下重复进行 5 次,最终结果取 5 次结果的平均值。

本文硬件实验环境为 64 位操作系统,Inter Core i7-8500 CPU,一片 RTX 2080Ti GPU,1T 内存;软件环境为 python3.7, Tensorflow 学习框架。

### 2.2.1 检验本文堆叠 LSTM 的有效性

为探究本文采用的 SLSTM 结构以及梯度消失缓解策略的有效性,本节对单层 LSTM,以及不同层数  $L$  的 SLSTM(SLSTM-sigmoid)和本文缓解梯度消失的 SLSTM(SLSTM-Elu) 3 种模型的识别性能进行了探究,实验选取经预处理的长度为 32 的 HRRP 序列作为模型的输入,最后一个时间步所提取的隐层特征输入到 Softmax 分类器种完成识别任务。层数  $L$  的取值为 1~10,层数  $L$  与识别性能之间的对应关系结果如图 7 所示。由图 7 可知,随着 LSTM 层数的递增,在一定范围内,两种 SLSTM 的识别率均保持上升趋势,证明了堆叠的多层 LSTM 模型的 HRRP 序列识别性能优于单层模型,这是由于多层结构具有更强的特征提取能力,可以提取到更多的深层抽象可分性特征,其中包括序列种相邻 HRRP 样本之间的时空相关性。另外,SLSTM-Elu 和 SLSTM-sigmoid 的识别率分别在 LSTM

层数为 6 和 3 之后出现下降,并在层数分别为 8 和 4 之后识别率低于单层模型,这是由于随着层数的增加,两种模型均出现了不同程度的梯度消失问题。值得注意的是,在每一个层数上,SLSTM-Elu 模型的识别率均高于 SLSTM-sigmoid 模型,并且识别率出现转折和低于单层 LSTM 所对应的层数均大于 SLSTM-sigmoid,这是由于采用 Elu 函数在一定程度上缓解了 SLSTM 的梯度消失现象,模型的每一步迭代均能学习到更深层的特征。综合以上分析,验证了本文采用的 SLSTM 模型在 HRRP 序列识别任务中具有有效性。




图 7 SLSTM 层数与识别率对应关系

Fig. 7 Corresponding relationship between SLSTM layers and accuracy

### 2.2.2 检验注意力机制的有效性

为了探究注意力机制在 Attention-SLSTM 中的有效性,从整体上检验本文所提方法在 HRRP 序列识别任务中的性能,本节设置了 SVM、RNN、LSTM、SLSTM 和 Attention-RNN 5 种对比实验,其中后 4 种深度学习模型的隐藏层节点数均设置为 64,批处理大小 batch\_size 设置为 32,最大 epoch 设置为 500,SLSTM、Attention-RNN 和 Attention-SLSTM 模型的最大堆叠层数设置为 10。各模型在不同堆叠层数设置上的识别率对比表如表 2 和表 3 所示。

表 2 单层模型识别率比较

Table 2 Comparison of single-layer model recognition accuracy

层数	模型	识别率
1	SVM	0.820 0
1	RNN	0.867 0
1	LSTM	0.882 4
1	SLSTM-sigmoid	0.890 9
1	SLSTM-Elu	0.905 4
1	Attention-RNN	0.910 5
1	Attention-SLSTM	0.948 0

表 3 多层模型识别率比较

Table 3 Comparison of multi-layer model recognition accuracy

层数	SLSTM-sigmoid	SLSTM-Elu	Attention-RNN	Attention-SLSTM
1	0.890 9	0.905 4	0.910 5	0.948 0
2	0.918 9	0.925 5	0.929 4	0.952 7
3	0.928 2	0.936 0	0.942 2	0.969 0
4	0.902 2	0.943 4	0.954 6	0.972 4
5	0.887 7	0.950 2	0.960 0	0.978 6
6	0.882 4	0.954 3	0.958 3	0.980 0
7	0.880 0	0.942 2	0.952 5	0.980 3
8	0.872 5	0.903 0	0.952 1	0.978 8
9	0.868 0	0.892 0	0.951 5	0.978 5
10	0.865 4	0.880 5	0.952 0	0.979 0

由表 2 和表 3 可知,深度学习模型的识别率高于 SVM 模型,这是由于深度学习模型具有更强的特征提取能力。另外,加入 Attention 机制的模型的识别率普遍高于对应的无 Attention 机制的识别率,其中,本文方法在堆叠层数为 7 时,取得了最高识别率,比无 Attention 机制的对应模型的最高识别率高 2.6%,验证了注意力机制在 HRRP 序列识别任务中识别率方面的有效性。

为进一步探究各模型在收敛速度和识别率方面的性能,图 8 给出了随着迭代次数的增加,6 种模型识别率的变化曲线。为保持各模型的最佳性能,RNN 和 LSTM 两种模型的参数设置保持不变,SLSTM-sigmoid 堆叠层数为 3,SLSTM-Elu 堆叠层数为 6,Attention-RNN 的堆叠层数为 5,其中 Attention-RNN 为基于注意力机制的 5 层堆叠式 RNN 网络模型。

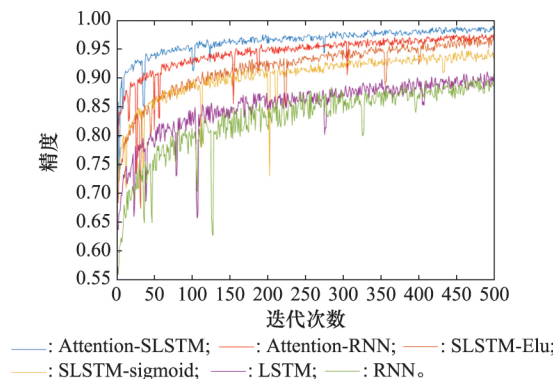


图 8 6 种模型识别率迭代曲线

Fig. 8 Iterative curve of recognition accuracy for 6 models

由图 8 可知,随着迭代次数的增加,几种模型的识别率均呈现上升趋势,其中,本文提出的 Attention-SLSTM 模型识别率最高,并且迭代数为 100 时最先达到相对稳定的识别率,验证了本文所提出方法具有收敛速度快的优点。另外,表 2 中单层模型识别率与本文方法最接近的 Attention-RNN 模型,在其堆叠层数为最优设置的情况下,识别率依然与本文所提 Attention-SLSTM 存在差距,验证了本文方法的有效性。综上,本文方法具有更快的收敛速度和更好的识别性能。

### 3 结 论

本文提出的 Attention-SLSTM 模型将 SLSTM 引入到 HRRP 序列识别任务,提高了模型的表达能力;通过替换 LSTM 模型激活函数,缓解了梯度消失问题;将注意力机制与 SLSTM 相结合,充分提取了 HRRP 序列中相邻样本之间的时空相关性及其他深层抽象特征,提高了模型的收敛速度和识别性能。在雷达实际工作环境中,HRRP 序列往往会出现样本缺失、噪声污染等问题,如何针对以上现实问题提出更有效的雷达 HRRP 序列目标识别方法,将会是下一步研究的重点方向。

### 参考文献

- [1] DU L, WANG P H, LIU H W, et al. Bayesian spatiotemporal multitask learning for radar HRRP target recognition[J]. IEEE Trans. on Signal Processing, 2011, 59(7):3182-3196.
- [2] 刘天坤,熊新平,赵育善. 网络化防空导弹体系生存能力的评估与权衡[J]. 系统工程与电子技术, 2007, 29(2): 226-229.  
LIU T K, XIONG X P, ZHAO Y S. Research on survivability evaluation and tradeoff of networking air defense missile systems[J]. Systems Engineering and Electronics, 2007, 29(2): 226-229.
- [3] CAPLAN P, SHIMIZU H, KOBAYASHI S, et al. Cataloging internet resources[J]. The Public Access Computer Systems Review, 1993, 4(2): 61-66.
- [4] 张怡霄,郭文普,康凯,等. 基于聚类与时序相关的重点雷达信号快速识别[J]. 系统工程与电子技术, 2020, 42(3): 597-602.  
ZHANG Y X, GUO W P, KANG K, et al. Key radar signal fast recognition method based on clustering and time-series correlation[J]. Systems Engineering and Electronics, 2020, 42(3): 577-602.
- [5] 徐彬,陈瀚,刘家麒,等. 采用双向 LSTM 模型的雷达 HRRP 目标识别[J]. 西安电子科技大学学报, 2019, 46(4): 29-34.  
XU B, CHEN B, LIU J Q, et al. Radar HRRP target recognition using bidirectional LSTM model[J]. Journal of Xidian University, 2019, 46(4): 29-34.
- [6] DU L, LIU H W, WANG P H, et al. Radar HRRP target recognition by the bidirectional LSTM model[J]. IEEE Trans. on Signal Processing, 2012, 60(7):3546-3559.
- [7] WANG C Y, HUANG P P, LI X F, et al. Radar HRRP target recognition based on AEPSO-SVM algorithm[J]. Systems Engineering and Electronics, 2019, 41(9): 1984-1989.
- [8] LAN D, WANG P H, LIU H W, et al. Radar HRRP target recognition based on dynamic multi-task hidden Markov model[C]//Proc. of the IEEE International Conference on National Radar, 2011: 253-255.
- [9] 王彩云,黄盼盼,李晓飞,等. 基于 AEPSO-SVM 算法的雷达 HRRP 目标识别[J]. 系统工程与电子技术, 2019, 41(9): 1984-1989.  
WANG C Y, HUANG P P, LI X F, et al. Radar HRRP target recognition based on AEPSO-SVM algorithm[J]. Systems Engineering and Electronics, 2019, 41(9): 1984-1989.
- [10] DEWI C, CHEN R C, HENDRY H, et al. Experiment improvement of restricted Boltzmann machine methods for image classification[J]. Vietnam Journal of Computer Science, 2021, 8(2): 134-141.
- [11] HSU K C, LI S T. Clustering spatial-temporal precipitation data using wavelet transform and self-organizing map neural network[J]. Advances in Water Resources, 2010, 33(2):190-200.
- [12] GUO Y, WANG S, GAO C, et al. Wishart RBM based DBN for polarimetric synthetic radar data classification[C]//Proc. of the IEEE International Geoscience and Remote Sensing Symposium, 2015.
- [13] 刘凯,张斌,黄青华. 基于 TCNN-BiLSTM 网络的调制识别算

- 法[J]. 系统工程与电子技术, 2020, 42(8): 1841–1849.
- LIU K, ZHANG B, HUANG Q H. Modulation recognition algorithm based on TCNN-BiLSTM[J]. Systems Engineering and Electronics, 2020, 42(8): 1841–1849.
- [14] GUO C, WANG H, JIANT T, et al. Radar target recognition based on feature pyramid fusion lightweight CNN[J]. IEEE Access, 2019, 7: 51140–51149.
- [15] ZHANG Y F, XIAO F, QIAN F C, et al. VGM-RNN: HRRP sequence extrapolation and recognition based on a novel optimized RNN[J]. IEEE Access, 2020, 8: 70071–70081.
- [16] LIU J, CHEN B, CHEN W, et al. Radar HRRP target recognition with target aware two-dimensional recurrent neural network[C]//Proc. of the IEEE International Conference on Signal Processing, Communications and Computing (ICSPCC), 2020.
- [17] LI X, HE Y, YANG Y, et al. LSTM based human activity classification on radar range Profile[C]//Proc. of the IEEE International Conference on Computational Electromagnetics, 2019.
- [18] WAN J W, CHEN B, LIU Y Q, et al. Recognizing the HRRP by combining CNN and BiRNN with attention mechanism[J]. IEEE Access, 2020, 8: 20828–20837.
- [19] WANG Y, HUANG M, ZHU X, et al. Attention-based LSTM for aspect-level sentiment classification[C]//Proc. of the Conference on Empirical Methods in Natural Language Processing, 2016.
- [20] YAN S, SMITH J S, LU W, et al. CHAM: action recognition using convolutional hierarchical attention model[C]//Proc. of the IEEE International Conference on Image Processing (ICIP), 2017.
- [21] WANG A H, CHEN J P, ZHANG Y Z, et al. Comparison of three widely used multi-GNSS real-time single-frequency precise point positioning models using the international GNSS service real-time service[J]. IET Radar Sonar Navigation, 2020, 14(1): 1–14.
- [22] DU C, ZHANG L, SUN X P, et al. Enhanced multi-channel feature synthesis for hand gesture recognition based on CNN with a channel and spatial attention mechanism[J]. IEEE Access, 2020, 8: 14610–14620.
- [23] CUI Z Y, WANG X Y, LIU N Y, et al. Ship detection in large-scale SAR images via spatial shuffle-group enhance attention[J]. IEEE Trans. on Geoscience and Remote Sensing, 2020, 59(1): 379–391.
- [24] ALBRECHT T W, GUSTAFSON S C. Hidden Markov models for classifying SAR target images[C]//Proc. of the Algorithms for Synthetic Aperture Radar Imagery XI. International Society for Optics and Photonics, 2004.
- [25] LIANG Z, HUANG J, LIU J P, et al. Enterprise master patient index entity recognition by long short-term memory network in electronic health systems[C]//Proc. of the British HCI 2018, 2018.
- [26] SHRESTHA A, LI H, KERNEC J L, et al. Continuous human activity classification from FMCW radar with Bi-LSTM networks[J]. IEEE Sensors Journal, 2020, 22(20): 13607–13619.
- [27] LI X, HE Y, YANG Y M, et al. LSTM based human activity classification on radar range profile[C]//Proc. of the IEEE International Conference on Computational Electromagnetics, 2019.
- [28] TIAN B, WANG G, XU Z, et al. Communication delay compensation for string stability of CACC system using LSTM prediction[J]. Vehicular Communications, 2021: 100333.
- [29] LI X, LIU Z, HUANG Z. Attention-based radar PRI modulation recognition with recurrent neural networks[J]. IEEE Access, 2020, 8: 57426–57436.
- [30] REN H, YU X, ZOU L, et al. Extended convolutional capsule network with application on SAR automatic target recognition[J]. Signal Processing, 2021, 183(1): 108021.
- [31] SUN Z, LIU M, LIU P, et al. SAR Image classification using fully connected conditional random fields combined with deep learning and superpixel boundary constraint[J]. Remote Sensing, 2021. DOI:10.3390/rs13020271.

## 作者简介

张一凡(1994—),男,助教,硕士,主要研究方向为雷达目标识别、深度学习。

张双辉(1989—),男,副研究员,博士,主要研究方向为雷达成像、压缩感知、贝叶斯推断。

刘永祥(1976—),男,教授,博士,主要研究方向为目标微动特性分析与识别。

荆 锋(1979—),男,副教授,博士,主要研究方向为智能信息处理。