



(12)发明专利申请

(10)申请公布号 CN 111736125 A

(43)申请公布日 2020. 10. 02

(21)申请号 202010256158.0

(22)申请日 2020.04.02

(71)申请人 杭州电子科技大学

地址 310018 浙江省杭州市下沙高教园区

(72)发明人 潘勉 吕帅帅 李训根 刘爱林

李子璇 张杰

(74)专利代理机构 浙江永鼎律师事务所 33233

代理人 陆永强

(51)Int.Cl.

G01S 7/41(2006.01)

G06K 9/62(2006.01)

G06N 3/04(2006.01)

G06N 3/08(2006.01)

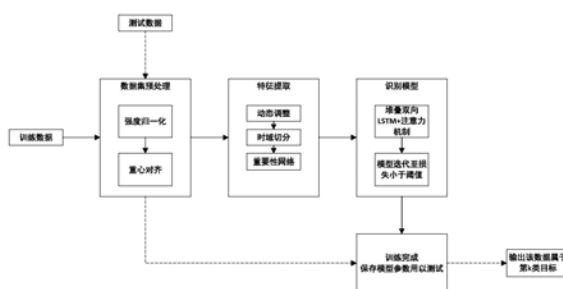
权利要求书4页 说明书10页 附图1页

(54)发明名称

基于注意力机制和双向堆叠循环神经网络的雷达目标识别方法

(57)摘要

本发明公开了一种基于注意力机制和双向堆叠循环神经网络的雷达目标识别方法,该方法首先进行预处理降低HRRP样本中的敏感性并建立动态调整层;然后选取滑窗尺寸对HRRP进行切分,滑窗移动距离小于滑窗长度;然后通过重要性网络调整各切分序列的重要程度;再通过双向堆叠RNN对样本的时序相关性进行建模,提取出其高层次特征;最后采用多层次的注意力机制调整隐层状态的重要程度并通过softmax进行目标分类。



1.一种基于注意力机制和双向堆叠循环神经网络的雷达目标识别方法,其特征在于,包括以下步骤:

S1,采集数据集,将雷达采集到的HRRP数据集依据目标的种类进行合并,每种种类的样本分别在不同的数据段里选择训练样本和测试样本,在训练集和测试集的选取过程中,保证所选取的训练集样本与雷达所成姿态涵盖测试集样本与雷达所成的姿态,各类目标训练集和测试集样本数的比例为8:2,将挑选的数据集记作 $T = \{(x_i, y_k)\} \mid i \in [1, n], k \in [1, c]$,其中 x_i 表示第 i 个样本, y_k 表示样本属于第 k 类,一共采集了 c 类目标, n 表示样本总数;

S2,对原始HRRP样本集进行预处理,由于HRRP的强度包括雷达发射功率、目标距离、雷达天线增益和雷达接收机增益因素共同决定,在利用HRRP进行目标识别前,通过 l_2 强度归一化的方法对原始HRRP回波进行处理,从而改善HRRP的强度敏感性问题;HRRP是通过距离窗从雷达回波数据中截取的,在截取的过程中录取的距离像在距离波门中的位置不固定,从而导致了HRRP的平移敏感性,通过重心对齐法改善HRRP的平移敏感性问题;

S3,由于HRRP中各距离单元内回波的幅度相差较大,直接将数据送入卷积层中会导致模型过多关注于幅度较大的距离单元,然而,幅度较小的距离单元中有可能包含一些可分性很强的特征,有助于进行雷达目标识别,在切分HRRP之前先加入动态调整层对HRRP进行整体的动态范围调整,该调整层在各距离单元大小相对关系未发生改变的前提下可通过模型训练以决定如何调整HRRP的整体动态,以达到更好的识别效果;

S4,选取固定长度的滑窗窗口对经过上述处理的HRRP样本进行切分,切分后的数据格式为后续深度神经网络的输入格式;

S5,搭建重要性调整网络对经过上述处理后的数据进行通道调整,重要性网络通过学习的方式来自动获取到每个特征通道的重要程度,然后依照这个重要程度去提升有用的特征并抑制对当前任务用处不大的特征;

S6,搭建深度神经分类,调参并进行优化,采用双向的循环神经网络,将HRRP数据分正反双向分别输入两个独立的RNN模型,并将得到的隐层进行拼接;

S7,对由S1采集到的测试数据进行训练阶段的步骤S2、S3、S4预处理操作;

S8,将经过S7处理的样本送入S6构建的模型中进行测试求得结果,即最后经过注意力机制的输出会通过softmax层进行分类,第 i 个HRRP测试样本 \mathbf{x}_{test}^i 对应于目标集中第 k 类雷达目标的概率可计算为:

$$P(k|\mathbf{x}_{test}) = \frac{\exp(\text{output}_k)}{\sum_{c_0=1}^c \exp(\text{output}_{c_0})}$$

其中 $\exp(\cdot)$ 表示取指数运算, c 表示类别个数。

2.如权利要求1所述的基于注意力机制和双向堆叠循环神经网络的雷达目标识别方法,其特征在于,所述S2进一步包括如下步骤:

S201,强度归一化,假设原始HRRP表示为 $\mathbf{x}_{raw} = [x_1, x_2, \dots, x_L]$,其中 L 表示HRRP内包含的距离单元总数,则强度归一化之后的HRRP表示为:

$$\mathbf{x} = \frac{\mathbf{x}_{raw}}{\|\mathbf{x}_{raw}\|_2},$$

S202, 样本对齐, 平移HRRP使其重心 g 移至 $L/2$ 附近, 这样HRRP中包含信息的那些距离单元将分布在中心附近, 其中HRRP重心 g 的计算方法如下:

$$g = \frac{\sum_{i=1}^L ix_i}{\sum_{i=1}^L x_i}$$

其中, x_i 为原始HRRP中第 i 维信号单元。

3. 如权利要求1所述的基于注意力机制和双向堆叠循环神经网络的雷达目标识别方法, 其特征在于, 所述S3进一步包括: 对HRRP样本进行动态调整, 即对样本进行多个幂次的处理, 对数据进行幂次处理, 是为了从多个角度反映出目标类别差异的多样性, 从多个角度将雷达HRRP中所蕴含的信息以多种不同的形式体现出来, 方便后续网络从多个角度提取特征进行识别, 动态调整层的输出可以表示为:

$$\mathbf{x}_{dynamic} = \sum_{i=1}^M \mathbf{x}_{dynamic}^i$$

其中, M 是动态调整层的通道数, 第 i 个动态调整通道 $\mathbf{x}_{dynamic}^i$ 可以表示为:

$$\mathbf{x}_{dynamic}^i = [x_1^{\alpha_i}, x_2^{\alpha_i}, \dots, x_L^{\alpha_i}]$$

其中, α_i 表示幂次变换的系数。

4. 如权利要求3所述的基于注意力机制和双向堆叠循环神经网络的雷达目标识别方法, 其特征在于, 所述S4进一步包括:

S401, 对经过动态调整以后的HRRP样本进行滑窗切分, 设定滑窗的长度为 N , 滑动的距离为 d , 其中 $d < N$, 即切割后相邻两段信号有长度为 $N-d$ 的重叠部分, 重叠切分更大化的保留了HRRP样本中的序列特征, 后续深度神经网络也能更大化的学习到样本中对分类更有用的特征, 其中切割的份数对应的是后续深度神经网络输入格式中的时间点维数, 滑窗的长度 N 对应的则是其中每一个时间点的输入信号维数;

S402, 滑窗切分后的输出可表示为:

$$\mathbf{x}_{slide} = [\mathbf{x}_{slide}^1, \mathbf{x}_{slide}^2, \dots, \mathbf{x}_{slide}^M]$$

其中 M 是经过切分后的序列个数, 其中第 t 个切分序列为

$$\mathbf{x}_{slide}^t = [x_{(t-1)d+1}, x_{(t-1)d+2}, \dots, x_{(t-1)d+N}]$$

其中, d 为窗口滑动距离, N 为滑窗长度。

5. 如权利要求4所述的基于注意力机制和双向堆叠循环神经网络的雷达目标识别方法, 其特征在于, 所述S5进一步包括:

S501, 重要性网络对切分后的HRRP进行重要性调整, 通过学习卷积通道的全局信息来有选择地强调蕴含可分性信息较多的某些时间点的输入序列并抑制另外一些不太重要的时间点的输入序列, 经过重要性网络调整后之后, 模型变得更加平衡, 使更重要、更有用的特征可以得到突显, 提高了模型表征HRRP能力, 重要性调整分为压缩特征和激发特征两部分;

S502, 压缩特征部分: 经过滑窗切分后的样本为 $\mathbf{x}_{slide} = [\mathbf{x}_{slide}^1, \mathbf{x}_{slide}^2, \dots, \mathbf{x}_{slide}^M]$, $\mathbf{x}_{slide} \in \mathbb{R}^{M \times N}$, 该特征由M个序列构成, 每个序列为一个N维的向量, 其中的每一个序列都会经过全连接层和激活函数压缩为一个代表此序列重要程度的实数权重 x_{sq} , x_{slide} 通过全连接的输出可由下式计算得到:

$$x_{sq} = f(Wx_{slide} + b)$$

其中激活函数 $f(\cdot)$ 为Sigmoid函数, $W \in \mathbb{R}^{N \times 1}$;

S503, 特征激发部分: 通过Excitation公式将提取到的特征进行选择性的调整, 得到经调整之后的特征 F_E :

$$F_E = x_{slide} \odot x_{sq}$$

其中 $x_{sq} = [x_{sq}(1), x_{sq}(2), \dots, x_{sq}(M)]$, 它是一个M维向量, \odot 表示将 x_{slide} 各通道中的每一个元素都乘上 x_{sq} 这个向量中对应维上的数, 如特征 F_E 中的第m个通道被调整为:

$$F_E^m = x_{sq}(m) x_{slide}^m$$

6. 如权利要求5所述的基于注意力机制和双向堆叠循环神经网络的雷达目标识别方法, 其特征在于, 具体地, 所述S6进一步包括:

S601, 分类网络设计为多层堆叠的双向RNN, 假设输入的是特征 F_{RNN} ,

$F_{RNN} = [F_{RNN}^1, F_{RNN}^2, \dots, F_{RNN}^N] \in \mathbb{R}^{M_i \times N}$ 其中 M_i 表示第i个双向RNN的各时间点维数, N表示输入序列长度, 假设其输出为 F_{output} , $F_{output} = [F_{output}(1), F_{output}(2), \dots, F_{output}(N)] \in \mathbb{R}^{M \times H}$, 其中H是隐单元个数, 其中序列中第k个时间点所对应的向量可表示为:

$$F_{output}(k) = f(\mathbf{W}_{hFi}^F h_{ik}^F + \mathbf{W}_{hFi}^B h_{ik}^B + \mathbf{b}_{Fi})$$

其中, $f(\cdot)$ 表示激活函数, \mathbf{W}_{hFi}^F 表示对应于第i个双向RNN中所包含的前向RNN的隐藏层输出矩阵, h_{ik}^F 表示第i个双向RNN中所包含的前向RNN中所包含的第k个隐藏层状态, 同样地, \mathbf{W}_{hFi}^B 表示对应于第i个双向RNN中所包含的后向RNN的隐藏层输出矩阵, h_{ik}^B 表示第i个双向RNN中所包含的后向RNN中所包含的第k个隐藏层状态, \mathbf{b}_{Fi} 表示第i个双向RNN的输出层偏置;

S602, 网络中的注意力机制, 选取最后几层双向RNN在不同时刻得到的隐层状态进行拼接, 第i层拼接后的隐层状态为:

$$c_{ATT}^i = [\alpha_{i1}(h_{i1}^F + h_{i1}^B), \alpha_{i2}(h_{i2}^F + h_{i2}^B), \dots, \alpha_{iM}(h_{iM}^F + h_{iM}^B)]$$

最后再将每一层拼接后隐层进行相加, 即得到经过注意力模型处理后的隐层状态 c_{ATT} 为:

$$c_{ATT} = \sum_{i=N_1-N_0+1}^{N_1} c_{ATT}^i$$

其中 α_{ik} 表示对应于第i层第k个时间点所对应的权重, M表示双向RNN模型中每层的前向

RNN或后向RNN包含的隐状态的个数,即时间点维数, N_1 表示网络堆叠的层数, N_0 表示取从最后一层开始数,共取几层堆叠双向RNN内的隐状态用于求 C_{ATT} , α_{ik} 的求法如下式所示:

$$\alpha_{ik} = \frac{\exp(e_{ik})}{\sum_{k=1}^M \exp(e_{ik})}$$

其中, e_{ik} 为第*i*个双向RNN中前向和后向隐藏状态进行相加后的能量,表示为:

$$e_{ik} = U_{ATT} \tanh(W_{ATT} h_{ik})$$

其中 $U_{ATT} \in \mathbb{R}^{1 \times M}$, $W_{ATT} \in \mathbb{R}^{M \times l}$, 它们用于计算隐单元能量的参数,1是隐单元的维数, M 是时间点维数;

S603, 损失函数设计为交叉熵,通过使用训练数据计算损失函数相对于参数的梯度来学习参数,并在模型收敛时固定学习的参数,采用基于交叉熵的代价函数,表示为:

$$L = - \sum_{n=1}^N \sum_{i=1}^M e_n(i) \log P(i | \mathbf{x}_{train})$$

其中, N 表示一个批次中训练样本的个数, e_n 是one-hot向量,用于表示第*n*个训练样本的真实标签, $P(i | \mathbf{x}_{train})$ 表示训练样本对应于第*i*个目标的概率。

基于注意力机制和双向堆叠循环神经网络的雷达目标识别方法

技术领域

[0001] 本发明属于雷达目标识别领域,具体涉及一种基于注意力机制和双向堆叠循环神经网络的雷达目标识别方法。

背景技术

[0002] 高分辨宽带雷达的距离分辨率远小于目标尺寸,其回波也被称为目标的一维高分辨距离像(High Resolution Range Profile,HRRP)。HRRP中包含了对分类和识别等极有价值的结构信息,如目标的径向尺寸、散射点分布等,具有广阔的工程应用前景。因此,基于HRRP的雷达自动目标识别方法逐步成为雷达自动目标识别领域研究的热点。

[0003] 对于绝大多数的HRRP目标识别系统而言,由于原始HRRP样本往往维数较高,往往很难直接体现识别对象的本质属性,因此,特征提取是其中的关键的一环。特征提取的主要工作是通过某种线性或非线性变换,为后续的分类任务提供某种帮助(如降低数据维数、强化判别信息等)。有效的特征不仅可以充分地表达数据,并且能够区分不同类别的差异性,从而提高识别的精度。

[0004] 传统的特征提取方法可分成两部分:(1)基于降维的特征提取方法;(2)基于变换(Transformer)的特征提取方法,如双谱、谱图以及频谱幅度特征等。这些方法将HRRP信号投影到频域中,然后对其频域特征进行建模识别。传统的特征提取方法在实验中取得了很好的识别性能,然而还存在以下两个问题:(1)特征提取的方式大多是无监督且有损的,这意味着可分性的信息将不可避免地在特征提取的过程中损失掉一部分,不利于后端分类器的识别。(2)特征提取方法的选择高度依赖于研究人员对于HRRP数据的认知和经验的积累,在某些缺乏先验信息的情况下难以达到令人满意的效果。

[0005] 为了解决传统方法在特征提取上存在的问题,近年来,基于深度学习的方法被引入到了雷达目标识别领域之中。基于深度学习的雷达高分辨距离像识别方法大致可分为以下三类:(1)基于编码器-解码器结构的深度学习方法。(2)基于卷积神经网络(CNN)结构的深度学习方法。(3)基于循环神经网络的深度学习方法。然而,方法(1)和(2)对HRRP整体的包络信息直接进行特征提取和建模,忽略了可反映目标物理结构特征的HRRP距离单元之间的序列相关性。方法(3)基于序列相关性进行建模,虽然对物理结构特征进行建模描述,但是存在以下几个问题:(1)幅度较小的距离单元中有可能包含一些可分性很强的特征,但这些特征很少被用到;(2)单向的RNN在预测时只能利用当前时刻及当前时刻之前的结构信息,无法很好利用HRRP中蕴含的整体结构信息先验。

发明内容

[0006] 鉴于以上存在的技术问题,本发明用于提供一种基于注意力机制和双向堆叠循环神经网络的雷达目标识别方法,首先进行预处理降低HRRP样本中的敏感性并建立动态调整层;然后选取滑窗尺寸对HRRP进行切分,滑窗移动距离小于滑窗长度;然后通过重要性网络

调整各切分序列的重要程度；再通过双向堆叠RNN对样本的时序相关性进行建模，提取出其高层次特征；最后采用多层次的注意力机制调整隐层状态的重要程度并通过softmax进行目标分类。

[0007] 为解决上述技术问题，本发明采用如下的技术方案：

[0008] 一种基于注意力机制和双向堆叠循环神经网络的雷达目标识别方法，包括以下步骤：

[0009] S1,采集数据集，将雷达采集到的HRRP数据集依据目标的种类进行合并，每种种类的样本分别在不同的数据段里选择训练样本和测试样本，在训练集和测试集的选取过程中，保证所选取的训练集样本与雷达所成姿态涵盖测试集样本与雷达所成的姿态，各类目标训练集和测试集样本数的比例为8:2，将挑选的数据集记作 $T = \{(x_i, y_k)\} \mid i \in [1, n], k \in [1, c]$ ，其中 x_i 表示第 i 个样本， y_k 表示样本属于第 k 类，一共采集了 c 类目标， n 表示样本总数；

[0010] S2,对原始HRRP样本集进行预处理，由于HRRP的强度包括雷达发射功率、目标距离、雷达天线增益和雷达接收机增益因素共同决定，在利用HRRP进行目标识别前，通过 l_2 强度归一化的方法对原始HRRP回波进行处理，从而改善HRRP的强度敏感性问题，HRRP是通过距离窗从雷达回波数据中截取的，在截取的过程中录取的距离像在距离波门中的位置不固定，从而导致了HRRP的平移敏感性，通过重心对齐法改善HRRP的平移敏感性问题；

[0011] S3,由于HRRP中各距离单元内回波的幅度相差较大，直接将数据送入卷积层中会导致模型过多关注于幅度较大的距离单元，然而，幅度较小的距离单元中有可能包含一些可分性很强的特征，有助于进行雷达目标识别，在切分HRRP之前先加入动态调整层对HRRP进行整体的动态范围调整，该调整层在各距离单元大小相对关系未发生改变的前提下可通过模型训练以决定如何调整HRRP的整体动态，以达到更好的识别效果；

[0012] S4,选取固定长度的滑窗窗口对经过上述处理的HRRP样本进行切分，切分后的数据格式为后续深度神经网络的输入格式；

[0013] S5,搭建重要性调整网络对经过上述处理后的数据进行通道调整，重要性网络通过学习的方式来自动获取到每个特征通道的重要程度，然后依照这个重要程度去提升有用的特征并抑制对当前任务用处不大的特征；

[0014] S6,搭建深度神经分类，调参并进行优化，采用双向的循环神经网络，将HRRP数据分正反双向分别输入两个独立的RNN模型，并将得到的隐层进行拼接；

[0015] S7,对由S1采集到的测试数据进行训练阶段的步骤S2、S3、S4预处理操作；

[0016] S8,将经过S7处理的样本送入S6构建的模型中进行测试求得结果，即最后经过注意力机制的输出会通过softmax层进行分类，第 i 个HRRP测试样本 \mathbf{x}_{test}^i 对应于目标集中第 k 类雷达目标的概率可计算为：

$$[0017] \quad P(k|\mathbf{x}_{test}) = \frac{\exp(\text{output}_k)}{\sum_{c_0=1}^c \exp(\text{output}_{c_0})}$$

[0018] 其中 $\exp(\cdot)$ 表示取指数运算， c 表示类别个数。

[0019] 优选地，所述S2进一步包括如下步骤：

[0020] S201,强度归一化，假设原始HRRP表示为 $\mathbf{x}_{raw} = [x_1, x_2, \dots, x_L]$ ，其中 L 表示HRRP内包含的距离单元总数，则强度归一化之后的HRRP表示为：

$$[0021] \quad \mathbf{x} = \frac{\mathbf{x}_{\text{raw}}}{\|\mathbf{x}_{\text{raw}}\|_2},$$

[0022] S202,样本对齐,平移HRRP使其重心g移至L/2附近,这样HRRP中包含信息的那些距离单元将分布在中心附近,其中HRRP重心g的计算方法如下:

$$[0023] \quad g = \frac{\sum_{i=1}^L ix_i}{\sum_{i=1}^L x_i}$$

[0024] 其中, x_i 为原始HRRP中第i维信号单元。

[0025] 优选地,所述S3进一步包括:对HRRP样本进行动态调整,即对样本进行多个幂次的处理,对数据进行幂次处理,是为了从多个角度反映出目标类别差异的多样性,从多个角度将雷达HRRP中所蕴含的信息以多种不同的形式体现出来,方便后续网络从多个角度提取特征进行识别,动态调整层的输出可以表示为:

$$[0026] \quad \mathbf{x}_{\text{dynamic}} = \sum_{i=1}^M \mathbf{x}_{\text{dynamic}}^i$$

[0027] 其中,M是动态调整层的通道数,第i个动态调整通道 $\mathbf{x}_{\text{dynamic}}^i$ 可以表示为:

$$[0028] \quad \mathbf{x}_{\text{dynamic}}^i = [x_1^{\alpha_i}, x_2^{\alpha_i}, \dots, x_L^{\alpha_i}]$$

[0029] 其中, α_i 表示幂次变换的系数。

[0030] 优选地,所述S4进一步包括:

[0031] S401,对经过动态调整以后的HRRP样本进行滑窗切分,设定滑窗的长度为N,滑动的距离为d,其中 $d < N$,即切割后相邻两段信号有长度为 $N-d$ 的重叠部分,重叠切分更大化的保留了HRRP样本中的序列特征,后续深度神经网络也能更大化的学习到样本中对分类更有用的特征,其中切割的份数对应的是后续深度神经网络输入格式中的时间点维数,滑窗的长度N对应的则是其中每一个时间点的输入信号维数;

[0032] S402,滑窗切分后的输出可表示为:

$$[0033] \quad \mathbf{x}_{\text{slide}} = [\mathbf{x}_{\text{slide}}^1, \mathbf{x}_{\text{slide}}^2, \dots, \mathbf{x}_{\text{slide}}^M]$$

[0034] 其中M是经过切分后的序列个数,其中第t个切分序列为

$$[0035] \quad \mathbf{x}_{\text{slide}}^t = [x_{(t-1)d+1}, x_{(t-1)d+2}, \dots, x_{(t-1)d+N}]$$

[0036] 其中,d为窗口滑动距离,N为滑窗长度。

[0037] 优选地,所述S5进一步包括:

[0038] S501,重要性网络对切分后的HRRP进行重要性调整,通过学习卷积通道的全局信息来有选择地强调蕴含可分性信息较多的某些时间点的输入序列并抑制另外一些不太重要的时间点的输入序列,经过重要性网络调整后之后,模型变得更加平衡,使更重要、更有用的特征可以得到突显,提高了模型表征HRRP能力,重要性调整分为压缩特征和激发特征两部分;

[0039] S502,压缩特征部分:经过滑窗切分后的样本为 $\mathbf{x}_{\text{slide}} = [\mathbf{x}_{\text{slide}}^1, \mathbf{x}_{\text{slide}}^2, \dots, \mathbf{x}_{\text{slide}}^M]$,

$\mathbf{x}_{slide} \in \mathbb{R}^{M \times N}$, 该特征由M个序列构成, 每个序列为一个N维的向量, 其中的每一个序列都会经过全连接层和激活函数压缩为一个代表此序列重要程度的实数权重 x_{sq} , \mathbf{x}_{slide} 通过全连接的输出可由下式计算得到:

$$[0040] \quad x_{sq} = f(Wx_{slide} + b)$$

[0041] 其中激活函数 $f(\cdot)$ 为Sigmoid函数, $W \in \mathbb{R}^{N \times 1}$;

[0042] S503, 特征激发部分: 通过Excitation公式将提取到的特征进行选择性的调整, 得到经调整之后的特征 F_E :

$$[0043] \quad F_E = x_{slide} \odot x_{sq}$$

[0044] 其中 $x_{sq} = [x_{sq}(1), x_{sq}(2), \dots, x_{sq}(M)]$, 它是一个M维向量, \odot 表示将 x_{slide} 各通道中的每一个元素都乘上 x_{sq} 这个向量中对应维上的数。如特征 F_E 中的第m个通道被调整为:

$$[0045] \quad F_E^m = x_{sq}(m)x_{slide}^m$$

[0046] 优选地, 具体地, 所述S6进一步包括:

[0047] S601, 分类网络设计为多层堆叠的双向RNN, 假设输入的是特征 F_{RNN} ,

$F_{RNN} = [F_{RNN}^1, F_{RNN}^2, \dots, F_{RNN}^N] \in \mathbb{R}^{M_i \times N}$ 其中 M_i 表示第i个双向RNN的各时间点维数, N表示输入序列长度, 假设其输出为 F_{output} , $F_{output} = [F_{output}(1), F_{output}(2), \dots, F_{output}(N)] \in \mathbb{R}^{M \times H}$, 其中H是隐单元个数, 其中序列中第k个时间点所对应的向量可表示为:

$$[0048] \quad F_{output}(k) = f(\mathbf{W}_{hFi}^F h_{ik}^F + \mathbf{W}_{hFi}^B h_{ik}^B + \mathbf{b}_{Fi})$$

[0049] 其中, $f(\cdot)$ 表示激活函数, \mathbf{W}_{hFi}^F 表示对应于第i个双向RNN中所包含的前向RNN的隐藏层输出矩阵, h_{ik}^F 表示第i个双向RNN中所包含的前向RNN中所包含的第k个隐藏层状态, 同样地, \mathbf{W}_{hFi}^B 表示对应于第i个双向RNN中所包含的后向RNN的隐藏层输出矩阵, h_{ik}^B 表示第i个双向RNN中所包含的后向RNN中所包含的第k个隐藏层状态, \mathbf{b}_{Fi} 表示第i个双向RNN的输出层偏置;

[0050] S602, 网络中的注意力机制, 选取最后几层双向RNN在不同时刻得到的隐层状态进行拼接, 第i层拼接后的隐层状态为:

$$[0051] \quad c_{ATT}^i = [\alpha_{i1}(h_{i1}^F + h_{i1}^B), \alpha_{i2}(h_{i2}^F + h_{i2}^B), \dots, \alpha_{iM}(h_{iM}^F + h_{iM}^B)]$$

[0052] 最后再将每一层拼接后隐层进行相加, 即得到经过注意力模型处理后的隐层状态 c_{ATT} 为:

$$[0053] \quad c_{ATT} = \sum_{i=N_1-N_0+1}^{N_1} c_{ATT}^i$$

[0054] 其中 α_{ik} 表示对应于第i层第k个时间点所对应的权重, M表示双向RNN模型中每层的前向RNN或后向RNN包含的隐状态的个数, 即时间点维数, N_1 表示网络堆叠的层数, N_0 表示取从最后一层开始数, 共取几层堆叠双向RNN内的隐状态用于求 c_{ATT} , α_{ik} 的求法如下式所示:

$$[0055] \quad \alpha_{ik} = \frac{\exp(e_{ik})}{\sum_{k=1}^M \exp(e_{ik})}$$

[0056] 其中, e_{ik} 为第 i 个双向RNN中前向和后向隐藏状态进行相加后的能量, 表示为:

$$[0057] \quad e_{ik} = U_{ATT} \tanh(W_{ATT} h_{ik})$$

[0058] 其中 $U_{ATT} \in \mathbb{R}^{1 \times M}$, $W_{ATT} \in \mathbb{R}^{M \times l}$, 它们是由于计算隐单元能量的参数, l 是隐单元的维数, M 是时间点维数;

[0059] S603, 损失函数设计为交叉熵, 通过使用训练数据计算损失函数相对于参数的梯度来学习参数, 并在模型收敛时固定学习的参数, 采用基于交叉熵的代价函数, 表示为:

$$[0060] \quad L = - \sum_{n=1}^N \sum_{i=1}^M e_n(i) \log P(i | \mathbf{x}_{train})$$

[0061] 其中, N 表示一个批次中训练样本的个数, e_n 是 one-hot 向量, 用于表示第 n 个训练样本的真实标签, $P(i | \mathbf{x}_{train})$ 表示训练样本对应于第 i 个目标的概率。

[0062] 采用本发明具有如下的有益效果:

[0063] (1) 本发明实施例中应用动态调整层, 因为某些较好的可分性特征可能由于相对幅值的原因, 很难影响后续分类器的决策, 通过动态调整层在各距离单元大小相对关系未发生改变的前提下通过模型训练以决定如何调整HRRP的整体动态, 以达到更好的识别效果。

[0064] (2) 本发明实施例中应用重要性调整网络, 它可通过学习卷积通道的全局信息来有选择地强调蕴含可分性信息较多的卷积通道并抑制不太有用的卷积通道。经过调整之后, 模型从空间通道(卷积通道)上看变得更加平衡, 使更重要、更有用的特征可以得到突显, 提高了模型表征HRRP能力。

[0065] (3) 本发明实施例和现有的基于HRRP结构建立的模型不同, 本发明实施例中堆叠使用双向循环神经网络, 使模型具备一定深度, 按这种方式组织的模型可以更好的依据数据的上下文逐步抽象出高层的结构特征, 并且各双向循环神经网络层内部的隐状态蕴含了不同层次的结构表示, 可帮助我们更好地应用HRRP进行识别。

[0066] (4) 本发明实施例应用注意力模型, 在分类的时候应该考虑加强中部信号聚集区域所给出判断的权重, 减少两侧噪声区域给出判断的权重, 并且在本发明实施例的模型中, 各双向循环神经网络层内部的隐状态蕴含了不同层次的结构表示, 我们可以结合不同层次的结构表示来进一步提高我们的识别结果。

附图说明

[0067] 图1为本发明实施例的基于注意力机制和双向堆叠循环神经网络的雷达目标识别方法的步骤流程图。

具体实施方式

[0068] 下面将结合本发明实施例中的附图, 对本发明实施例中的技术方案进行清楚、完整地描述, 显然, 所描述的实施例是本发明一部分实施例, 而不是全部的实施例。基于本发明中的实施例, 本领域普通技术人员在没有做出创造性劳动前提下所获得的所有其他实施

例,都属于本发明保护的范围。

[0069] 参照图1,所示为本发明实施例的基于注意力机制和双向堆叠循环神经网络的雷达目标识别方法的步骤流程图,具体的,包括以下步骤:

[0070] S1,采集数据集,将雷达采集到的HRRP数据集依据目标的种类进行合并,每种种类的样本分别在不同的数据段里选择训练样本和测试样本,在训练集和测试集的选取过程中,保证所选取的训练集样本与雷达所成姿态涵盖测试集样本与雷达所成的姿态,各类目标训练集和测试集样本数的比例为8:2,将挑选的数据集记作 $T = \{(x_i, y_k)\} \{i \in [1, n], k \in [1, c]\}$,其中 x_i 表示第 i 个样本, y_k 表示样本属于第 k 类,一共采集了 c 类目标, n 表示样本总数;

[0071] S2,对原始HRRP样本集进行预处理,由于HRRP的强度包括雷达发射功率、目标距离、雷达天线增益和雷达接收机增益因素共同决定,在利用HRRP进行目标识别前,通过 l_2 强度归一化的方法对原始HRRP回波进行处理,从而改善HRRP的强度敏感性问题,HRRP是通过距离窗从雷达回波数据中截取的,在截取的过程中录取的距离像在距离波门中的位置不固定,从而导致了HRRP的平移敏感性,通过重心对齐法改善HRRP的平移敏感性问题;

[0072] 具体地,S2进一步包括以下步骤:

[0073] S201,强度归一化,假设原始HRRP表示为 $x_{\text{raw}} = [x_1, x_2, \dots, x_L]$,其中 L 表示HRRP内包含的距离单元总数,则强度归一化之后的HRRP可以表示为:

$$[0074] \quad \mathbf{x} = \frac{\mathbf{x}_{\text{raw}}}{\|\mathbf{x}_{\text{raw}}\|_2}$$

[0075] S202,样本对齐。平移HRRP使其重心 g 移至 $L/2$ 附近,这样HRRP中包含信息的那些距离单元将分布在中心附近。其中HRRP重心 g 的计算方法如下:

$$[0076] \quad g = \frac{\sum_{i=1}^L ix_i}{\sum_{i=1}^L x_i}$$

[0077] 其中, x_i 为原始HRRP中第 i 维信号单元。

[0078] 原始HRRP样本经过强度归一化和重心对齐法处理之后幅值已经被限制在0-1之间,不仅统一了尺度,而且在0-1之间的数值非常有利于后续的神经网络处理;分布偏右或偏左的HRRP回波信号都被调整到了中心点附近。

[0079] S3,由于HRRP中各距离单元内回波的幅度相差较大,直接将数据送入卷积层中会导致模型过多关注于幅度较大的距离单元,然而,幅度较小的距离单元中有可能包含一些可分性很强的特征,有助于进行雷达目标识别,在切分HRRP之前先加入动态调整层对HRRP进行整体的动态范围调整,该调整层在各距离单元大小相对关系未发生改变的前提下可通过模型训练以决定如何调整HRRP的整体动态,以达到更好的识别效果;

[0080] 所述S3进一步包括,对HRRP样本进行动态调整,即对样本进行多个幂次的处理,对数据进行幂次处理,是为了从多个角度反映出目标类别差异的多样性,从多个角度将雷达HRRP中所蕴含的信息以多种不同的形式体现出来,方便后续网络从多个角度提取特征进行识别,动态调整层的输出可以表示为:

$$[0081] \quad \mathbf{x}_{\text{dynamic}} = \sum_{i=1}^M \mathbf{x}_{\text{dynamic}}^i$$

[0082] 其中,M是动态调整层的通道数,第i个动态调整通道 $\mathbf{x}_{dynamic}^i$ 可以表示为

$$[0083] \quad \mathbf{x}_{dynamic}^i = [x_1^{\alpha_i}, x_2^{\alpha_i}, \dots, x_L^{\alpha_i}]$$

[0084] 其中, α_i 表示幂次变换的系数。

[0085] S4,选取固定长度的滑窗窗口对经过上述处理的HRRP样本进行切分,切分后的数据格式为后续深度神经网络的输入格式;

[0086] 所述S4进一步包括:

[0087] S401,对经过动态调整以后的HRRP样本进行滑窗切分,设定滑窗的长度为N,滑动的距离为d,其中 $d < N$,即切割后相邻两段信号有长度为 $N-d$ 的重叠部分,重叠切分更大化的保留了HRRP样本中的序列特征,后续深度神经网络也能更大化的学习到样本中对分类更有用的特征,其中切割的份数对应的是后续深度神经网络输入格式中的时间点维数,滑窗的长度N对应的则是其中每一个时间点的输入信号维数;

[0088] S402,滑窗切分后的输出可表示为:

$$[0089] \quad \mathbf{x}_{slide} = [\mathbf{x}_{slide}^1, \mathbf{x}_{slide}^2, \dots, \mathbf{x}_{slide}^M]$$

[0090] 其中M是经过切分后的序列个数,其中第t个切分序列为

$$[0091] \quad \mathbf{x}_{slide}^t = [x_{(t-1)d+1}, x_{(t-1)d+2}, \dots, x_{(t-1)d+N}]$$

[0092] 其中,d为窗口滑动距离,N为滑窗长度。

[0093] S5,搭建重要性调整网络对经过上述处理后的数据进行通道调整,重要性网络通过学习的方式来自动获取到每个特征通道的重要程度,然后依照这个重要程度去提升有用的特征并抑制对当前任务用处不大的特征;

[0094] 具体地,所述S5进一步包括:

[0095] S501,重要性网络对切分后的HRRP进行重要性调整,通过学习卷积通道的全局信息来有选择地强调蕴含可分性信息较多的某些时间点的输入序列并抑制另外一些不太重要的时间点的输入序列,经过重要性网络调整后之后,模型变得更加平衡,使更重要、更有用的特征可以得到突显,提高了模型表征HRRP能力,重要性调整分为压缩特征和激发特征两部分;

[0096] S502,压缩特征部分:经过滑窗切分后的样本为 $\mathbf{x}_{slide} = [\mathbf{x}_{slide}^1, \mathbf{x}_{slide}^2, \dots, \mathbf{x}_{slide}^M]$,

$\mathbf{x}_{slide} \in \mathbb{R}^{M \times N}$,该特征由M个序列构成,每个序列为一个N维的向量,其中的每一个序列都会经过全连接层和激活函数压缩为一个代表此序列重要程度的实数权重 x_{sq} , \mathbf{x}_{slide} 通过全连接的输出可由下式计算得到:

$$[0097] \quad x_{sq} = f(W\mathbf{x}_{slide} + b)$$

[0098] 其中激活函数 $f(\cdot)$ 为Sigmoid函数, $W \in \mathbb{R}^{N \times 1}$;

[0099] S503,特征激发部分:通过Excitation公式将提取到的特征进行选择性的调整,得到经调整之后的特征 F_E :

$$[0100] \quad F_E = \mathbf{x}_{slide} \odot \mathbf{x}_{sq}$$

[0101] 其中 $\mathbf{x}_{sq} = [x_{sq}(1), x_{sq}(2), \dots, x_{sq}(M)]$,它是一个M维向量, \odot 表示将 \mathbf{x}_{slide} 各通道中

的每一个元素都乘上 x_{sq} 这个向量中对应维上的数。如特征 F_E 中的第 m 个通道被调整为:

$$[0102] \quad F_E^m = x_{sq}(m)x_{slide}^m。$$

[0103] S6,搭建深度神经分类,调参并进行优化,采用双向的循环神经网络,将HRRP数据分正反双向分别输入两个独立的RNN模型,并将得到的隐层进行拼接。

[0104] 传统RNN模型是单向的,HRRP数据输入传统模型时只能沿着一个方向输入,导致了当前时刻的输入只和在其之前的输入数据具备条件依赖性,之后时刻的输入信息在当前时刻无法得以有效的应用。然而HRRP内包含了目标整体的物理结构先验,只考虑单向信息不利于对HRRP特征的建模识别。特别的,应用单向RNN的时候,当时间 t 较小的时候,已观察到的数据信息绝大多数都是噪声数据,此时RNN很难对目标结构特性进行准确建模。因此本发明实施例中采用了双向的循环神经网络,它将HRRP数据分正反双向分别输入两个独立的RNN模型,并将得到的隐层进行拼接,这样可改善单向RNN的缺陷,使之可更好的对HRRP内部蕴含的物理结构特性进行建模。本发明实施例使用堆叠双向循环神经网络,使模型具备一定深度。按这种方式组织的模型可以更好的依赖数据的上下文逐步抽象出高层的结构特征,并且各双向循环神经网络层内部的隐状态蕴含了不同层次的结构表示,可帮助更好地应用HRRP进行识别。在上述基础应用注意力模型,即在分类的时候考虑加强中部信号聚集区域所给出判断的权重,减少两侧噪声区域给出判断的权重。即本发明实施例中的深度神经网络模型由五层带有注意力机制的双向LSTM(长短时记忆网络)堆叠构成,最后采用softmax层对网络的输出进行分类。

[0105] 具体地,所述S6进一步包括:

[0106] S601,假设输入的是特征 F_{RNN} , $F_{RNN} = [F_{RNN}^1, F_{RNN}^2, \dots, F_{RNN}^N] \in \mathbb{R}^{M_i \times N}$ 其中 M_i 表示第 i 个双向RNN的各时间点维数, N 表示输入序列长度,假设其输出为 F_{output} ,

$F_{output} = [F_{output}(1), F_{output}(2), \dots, F_{output}(N)] \in \mathbb{R}^{M \times H}$, 其中 H 是隐单元个数,其中序列中第 k 个时间点所对应的向量可表示为:

$$[0107] \quad F_{output}(k) = f(\mathbf{W}_{hFi}^F h_{ik}^F + \mathbf{W}_{hFi}^B h_{ik}^B + \mathbf{b}_{Fi})$$

[0108] 其中, $f(\cdot)$ 表示激活函数, \mathbf{W}_{hFi}^F 表示对应于第 i 个双向RNN中所包含的前向RNN的隐藏层输出矩阵, h_{ik}^F 表示第 i 个双向RNN中所包含的前向RNN中所包含的第 k 个隐藏层状态,同样地, \mathbf{W}_{hFi}^B 表示对应于第 i 个双向RNN中所包含的后向RNN的隐藏层输出矩阵, h_{ik}^B 表示第 i 个双向RNN中所包含的后向RNN中所包含的第 k 个隐藏层状态, \mathbf{b}_{Fi} 表示第 i 个双向RNN的输出层偏置。

[0109] S602,选取最后几层双向RNN在不同时刻得到的隐层状态进行拼接,第 i 层拼接后的隐层状态为:

$$[0110] \quad c_{ATT}^i = [\alpha_{i1}(h_{i1}^F + h_{i1}^B), \alpha_{i2}(h_{i2}^F + h_{i2}^B), \dots, \alpha_{iM}(h_{iM}^F + h_{iM}^B)]$$

[0111] 最后再将每一层拼接后隐层进行相加,即得到经过注意力模型处理后的隐层状态 c_{ATT} 为:

$$[0112] \quad c_{ATT} = \sum_{i=N_1-N_0+1}^{N_1} c_{ATT}^i$$

[0113] 其中 α_{ik} 表示对应于第 i 层第 k 个时间点所对应的权重, M 表示双向RNN模型中每层的前向RNN或后向RNN包含的隐状态的个数,即时间点维数, N_1 表示网络堆叠的层数, N_0 表示取从最后一层开始数,共取几层堆叠双向RNN内的隐状态用于求 $c_{ATT} \circ \alpha_{ik}$ 的求法如下式所示:

$$[0114] \quad \alpha_{ik} = \frac{\exp(e_{ik})}{\sum_{k=1}^M \exp(e_{ik})}$$

[0115] 其中, e_{ik} 为第 i 个双向RNN中前向和后向隐藏状态进行相加后的能量,可以表示为:

$$[0116] \quad e_{ik} = U_{ATT} \tanh(W_{ATT} h_{ik})$$

[0117] 其中 $U_{ATT} \in \mathbb{R}^{1 \times M}$, $W_{ATT} \in \mathbb{R}^{M \times l}$,它们用于计算隐单元能量的参数, l 是隐单元的维数, M 是时间点维数。

[0118] S603,将经过注意力机制的输出进行拼接操作,再后接一个节点数为雷达类别数的全连接层,即全连接层的输出为模型的预测结果,输出可表示为:

$$[0119] \quad \text{output} = f(C(c_{ATT}) W_o)$$

[0120] 其中 $C(\cdot)$ 为拼接操作, $W_o \in \mathbb{R}^{(M \times l) \times c}$, c 表示类别个数, $f(\cdot)$ 表示softmax函数。

[0121] S604,损失函数设计为交叉熵。通过使用训练数据计算损失函数相对于参数的梯度来学习参数,并在模型收敛时固定学习的参数。本发明采用基于交叉熵的代价函数,可以表示为:

$$[0122] \quad L = - \sum_{n=1}^N \sum_{i=1}^M e_n(i) \log P(i | \mathbf{x}_{\text{train}})$$

[0123] 其中, N 表示一个批次中训练样本的个数, e_n 是one-hot向量,用于表示第 n 个训练样本的真实标签, $P(i | \mathbf{x}_{\text{train}})$ 表示训练样本对应于第 i 个目标的概率。

[0124] S605,初始化上述模型中所有待训练的权重及偏置,设置训练参数,包括学习率、每批次训练数据量、训练批次,开启模型训练。

[0125] S7,对由S1采集到的测试数据进行训练阶段的步骤S2、S3、S4预处理操作;

[0126] S8,将经过S7处理的样本送入S6构建的模型中进行测试求得结果,即最后经过注意力机制的输出会通过softmax层进行分类,第 i 个HRRP测试样本 $\mathbf{x}_{\text{test}}^i$ 对应于目标集中第 k 类雷达目标的概率可计算为:

$$[0127] \quad P(k | \mathbf{x}_{\text{test}}) = \frac{\exp(\text{output}_k)}{\sum_{c_0=1}^c \exp(\text{output}_{c_0})}$$

[0128] 其中 $\exp(\cdot)$ 表示取指数运算, c 表示类别个数。

[0129] 通过最大后验概率将测试HRRP样本 \mathbf{x}_{test} 分类到最大目标概率的 k_0 中:

$$[0130] \quad k_0 = \arg \max_k P(k | \mathbf{x}_{\text{test}})$$

[0131] 经过上述8个步骤,即可得到本发明所提出的一种基于注意力机制和双向堆叠循环神经网络的雷达目标识别模型。

[0132] 应当理解,本文所述的示例性实施例是说明性的而非限制性的。尽管结合附图描

述了本发明的一个或多个实施例,本领域普通技术人员应当理解,在不脱离通过所附权利要求所限定的本发明的精神和范围的情况下,可以做出各种形式和细节的改变。

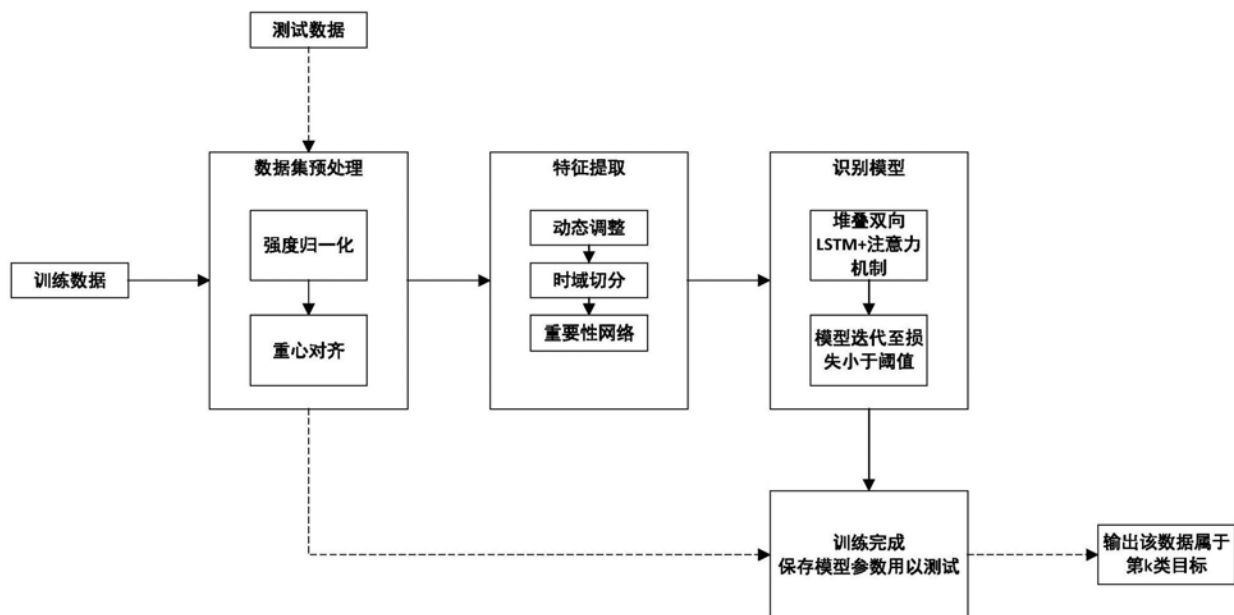


图1