

基于 CNN+LSTM 的空间目标识别

张耀天, 吴智昌, 魏少明, 张玉玺

北京航空航天大学 电子信息工程学院, 北京 100083

摘要: 雷达回波信号包含丰富的特征信息, 如时频特征、HRRP 和 RCS 等。本文提出了基于特征融合的空间目标识别方法, 采用 CNN 和 LSTM 组合的深度学习网络, 利用雷达回波信号的时频特征和 HRRP 特征进行融合识别。本文仿真的训练集和测试集存在多种信噪比(-5dB, -10dB 和 -15dB)。在上述数据集上, 该方法的分类精度能够达到 93.90%。

关键词: 时频特征; HRRP; 特征融合; CNN; LSTM

文献标志码: A **中图分类号:** TN959.17

Spatial Target Recognition Based on CNN and LSTM

ZHANG Yaotian, Wu Zhichang, WEI Shaoming, ZHANG Yuxi

School of Electronic and Information Engineering, Beihang University, Beijing 100083, China

Abstract: The radar echo signal contains rich characteristic information, such as time-frequency feature, HRRP and RCS, etc. A space target recognition method based on feature fusion is proposed in this paper, which adopts a deep learning network composed of CNN and LSTM and uses the time-frequency and HRRP features of radar echo signals for fusion recognition. There are many SNRs (-5dB, -10dB and -15dB) in the training dataset and test dataset. On the above dataset, the classification accuracy can reach 93.90%.

Key words: time-frequency feature; HRRP; feature fusion; CNN; LSTM

1 引言

目标识别技术是国内外研究的热点, 具有重要的军事意义。随着现代雷达技术的不断发展, 当前许多雷达系统都可以提供目标所对应的宽窄带回波信息, 该信息包含时频特征、HRRP (high resolution range profile) 和 RCS 等多种特征。

时频特征是通过将回波信号进行短时傅里叶变换得到的, 是一种包含丰富目标信息的二维特征。HRRP 反映了目标在雷达散射视线方向的散射强度分布和相对位置, 相对于时频特征, HRRP 是一种一维特征。RCS 反映了目标的窄带电磁散射特性, 是一种窄带特征。通常, 不同的特征代表着目标不同的物理特性, 因此, 将某些特征进行融合识别,

理论上识别的效果会提高。

事实上, 特征融合已经广泛应用到目标识别领域, 融合识别方法也多种多样。传统方法中主要有: D-S 证据理论^[1]、卡尔曼滤波^[2]和投票原则等。而随着深度学习的蓬勃发展, 它也成为融合识别中的一种重要方法。相对于传统方法, 深度学习是通过网络自我学习提取目标深层次的特征来实现目标分类, 它在传统的光学图像上已取得非常惊人的效果, 也越来越多应用到雷达信号处理上。

特征融合主要分为前期融合和后期融合两种方法: 前期融合是将雷达目标多种特征按照特定排列方式组合成高维的特征向量, 是在特征级上进行融合处理; 后期融合是分别对雷达目标的各个特征上进行处理, 然后将结果按照特定的融合方法, 如

作者简介: 张耀天(1981—), 男, 甘肃人, 北京航空航天大学副研究员, 研究方向为微动多普勒效应的生命探测方法; 吴智昌(1993—), 男, 安徽人, 北京航空航天大学硕士生, 研究方向为信息与信号处理; 魏少明(1985—), 男, 河南人, 博士, 实验师。主要研究方向: 目标跟踪, 雷达散射中心提取, 目标三维重构; 张玉玺(1985—), 男, 实验师, 研究领域为信号实时处理, FPGA/DSP 嵌入式系统, 雷达算法, 实验教学等, E-mail: zhangyuxi@buaa.edu.cn

线性组合、投票等方式，在决策层进行融合。

本文基于特征融合的空间目标识别方法，采用 CNN (convolution neural network) 和 LSTM (long-short memory network) 组合的深度学习网络，利用雷达回波信号的时频特征和 HRRP 特征进行融合识别。首先，通过 CNN 提取目标回波的时频特征得到一维特征，其次将 CNN 提取的一维特征与 HRRP 特征进行特征融合，得到高维特征。然后利用信号的时间关联性，将融合的特征送入 LSTM 网络训练。最后将 LSTM 输出的结果送入全连接层和 SoftMax 判决，得到最终分类结果。

2 CNN 和 LSTM 简介

该部分主要介绍卷积神经网络(CNN)和循环神经网络(RNN)结构。

2.1 卷积神经网络

卷积神经网络是一种前馈神经网络，是深度学习应用于图像分类识别的经典模型，相较于传统的神经网络，它引入了卷积层和池化层，于 1998 年 LeCun 提出并应用于 MINST^[3]。CNN 网络结构一般如下图所示。




图 1 经典的 CNN 网络结构

上图中的卷积层完成输入图像与卷积核卷积运算。它是基于“感受野”的概念，通过局部感受图像区域，提取图像特征，然后在更高层综合得到图像的全局信息。卷积层内部采用稀疏连接和权值共享机制，可以降低参数量。

池化层是对提取的特征进行降采样，避免过拟合。同时，增加池化层可以对特征聚类，降低参数量。一般有两种池化方式：一种是均值池化，即输出池化区域的均值；一种是最大值池化，即输出池化区域的最大值。

其后的全连接层和 Softmax 层与传统神经网络一致这里不再赘述。激活函数采用 Relu 函数^[4-5]。CNN 网络由于层数巨多，容易出现过拟合现象，而且训练时间很长。为此，又会在上述结构中增加 dropout 层^[6-8]，BN (batch normalization) 层^[9]等，以避免过拟合并减少训练时间。

2.2 卷积神经网络

传统神经网络模型中，层与层是全连接的，而每层间的节点是无法连接的，即只能利用当前信息，无法提取时间维度上的信息。由 Jordan^[10] 和 Elman^[11] 分别于 1986 年和 1990 年提出的循环神经网络能够记住并利用时间信息。但 RNN 在时间维度上存在梯度弥散和梯度爆炸的问题^[12-14]，由 Hochreiter 和 Schmidhuber 于 1997 年提出的长短期记忆网络能够有效的解决传统 RNN 的问题^[15]。相较于传统的 RNN 单元，LSTM 单元结构相对复杂，它的核心是通过一种称为“门”结构来去除或保留信息到单元。一个 LSTM 单元内部由三个“门”结构来控制 LSTM 选择利用前一时刻的信息和当前输入信息来更新单元状态，避免传统 RNN 在时间维度上出现梯度弥散和梯度爆炸的问题。

3 网络模型

本文采用 CNN-LSTM 网络模型，首先通过 CNN 提取雷达回波时频特征的深层一维信息，然后将 CNN 提取的一维特征与 HRRP 融合拼接在一起，最后利用 RNN 提取融合特征信息，通过 Softmax 层判决输出。整个网络结构如下图所示。




图 2 CNN-RNN 网络模型

从上图中可以看出，通过 CNN 提取时频特征的一维信息。整个 CNN 包括 5 层卷积层和 5 层池化层以及 1 层全连接层。5 层卷积层结构类似，仅仅只是通道数不同，内部都采用 3x3 大小的卷积核，以减少参数量；池化层采用最大值池化的方式。时频特征首先通过卷积层卷积，池化层降采样，提取深层特征，然后通过全连接层得到一维特征信息。

考虑到 HRRP 为雷达一维特征信息，本文通过一个全连接层来提取特征。在 CNN 提取得到时频一维特征信息后，无法和全连接层提取的 HRRP 特征直接送入 LSTM 网络，需要将二者特征融合。融合的方式有很多，本文采用 concat 层将二者拼接在一起。

通过 concat 层得到时频和 HRRP 的融合特征后, 将融合特征送入 LSTM 网络。

4 仿真及结果

4.1 数据来源

本文的数据是通过 matlab 仿真获得的, 一共仿真了 4 类空间目标, 目标的参数设置如下表所示。

表 1 目标参数设置

Num	类型	几何参数	微动参数
1	锥体	锥体高度 1.2m	进动角 10deg
		底面半径 0.5m	进动频率 0.2Hz
2	锥柱体	锥体高度 0.48m	自选频率 2Hz
		柱体高度 0.72m	进动角 10deg
3	柱体	柱体高度 1.2m	进动频率 0.2Hz
		底面半径 0.5m	自选频率 2Hz
4	锥体	锥体高度 1.0m	进动角 12deg
		底面半径 0.4m	进动频率 0.3Hz

采用 X 波段雷达, 带宽为 2GHz, 脉冲重复频率为 20Hz, 仿真得到各目标在微动情况下的回波, 同时考虑到环境噪声的影响, 每类目标生成 3 中不同信噪比(-5dB, -15dB 和-25dB)的回波信号。利用回波信号生成 HRRP 信号和时频图, 图 3 和图 4 分别为四类目标在-5dB 下的 HRRP 和时频图。

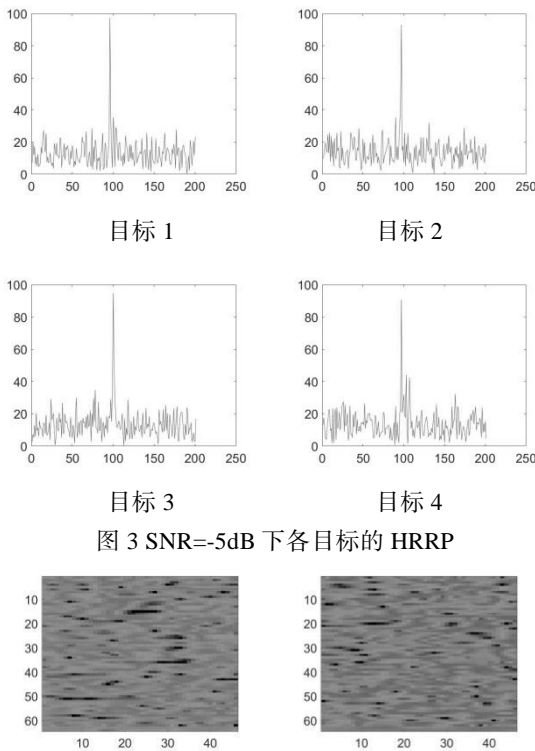


图 3 SNR=-5dB 下各目标的 HRRP




图 4 SNR=-5dB 下各目标的时频特征

4.2 仿真结果

本文首先分别对回波的时频特征和 HRRP 进行单独测试, 然后对二者进行融合测试, 对融合识别的有效性进行分析。下面对三个实验作简要介绍。

首先是时频特征的测试实验。考虑到时频特征是二维特征, 可以利用 CNN 提取深层特征, 然后利用 LSTM 网络进行分类识别。实验结果如下表所示。

表 2 时频特征测试结果

脉压前 SNR	-5dB	-15dB	-25dB
1	0.9644	0.7848	0.8960
2	0.9916	0.9988	0.9992
3	0.9464	0.7564	0.4324
4	0.9992	0.9972	0.9920
平均精度	0.9754	0.8843	0.8299

对于 HRRP 特征, 本身为一维特征, 可以直接利用 LSTM 网络进行测试。测试结果如下表所示。

表 3 HRRP 测试结果

脉压前 SNR	-5dB	-15dB	-25dB
1	0.9988	0.9762	0.6528
2	0.9988	0.9988	0.9982
3	0.9984	0.9358	0.6664
4	1.0000	0.9982	0.9990
平均精度	0.999	0.97725	0.8291

而时频特征和 HRRP 的融合测试结果如下表所示。

表 4 融合识别测试结果

脉压前 SNR	-5dB	-15dB	-25dB
1	0.9944	0.9780	0.8544
2	0.9996	0.9872	0.9940
3	1.0000	0.9796	0.5816
4	0.9996	0.9992	0.9976
平均精度	0.9984	0.9860	0.8569

从仿真结果可以看出, 利用 HRRP 分类识别的效果要好于时频特征, 而时频特征和 HRRP 的融合效果相较于单单 HRRP 测试有一定的提升。

5 结束语

本文针对空间目标, 提出了基于特征融合的空间目标识别方法。为此, 本文通过 MATLAB 仿真了基于锥体、锥柱体和柱体等四类目标。从仿真结

果可以看出,采用特征融合的识别方式能够有效地提高网络的识别效果。

参考文献

- [1] Bertolini M, Bevilacqua M. A combined goal programming—AHP approach to maintenance selection problem[J]. Reliability Engineering & System Safety, 2006, 91(7):839-848.
- [2] Gungor V C, Lambert F C. A survey on communication networks for electric system automation[J]. Computer Networks, 2006, 50(7):877-897.
- [3] Lecun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.
- [4] L. Deng, D. Yu. Deep Learning: Methods and Applications[M]. Now Publishers Inc, 2014.
- [5] Nair V, Hinton G E. Rectified Linear Units Improve Restricted Boltzmann Machines[C]. International Conference on Machine Learning, 2010.
- [6] Krizhevsky A, Sutskever I, Hinton G E, et al. ImageNet Classification with Deep Convolutional Neural Networks[C]. Neural Information Processing Systems, 2012.
- [7] Hinton G E, Srivastava N, Krizhevsky A, et al. Improving neural networks by preventing co-adaptation of feature detectors[J]. Computer Science, 2012, 3(4):págs. 212-223.
- [8] Srivastava N, Hinton G E, Krizhevsky A, et al. Dropout: a simple way to prevent neural networks from overfitting[J]. Journal of Machine Learning Research, 2014, 15(1): 1929-1958.
- [9] Ioffe S, Szegedy C. Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift[C]. International Conference on Machine Learning, 2015.
- [10] Jordan M I. Serial order: A parallel distributed processing approach[J]. Advances in psychology, 1997, 121: 471-495.
- [11] Elman J L. Finding structure in time[J]. Cognitive science, 1990, 14 (2): 179-211.
- [12] Hochreiter S. Untersuchungen zu dynamischen neuronalen Netzen[J]. Diploma, Technische Universität München, 1991.
- [13] Hochreiter S, Bengio Y, Frasconi P, et al. Gradient flow in recurrent nets: the difficulty of learning long-term dependencies[J]. 2001.
- [14] Bengio Y, Simard P, Frasconi P. Learning long-term dependencies with gradient descent is difficult[J]. Neural Networks, IEEE Transactions on, 1994, 5 (2): 157-166.
- [15] Hochreiter S, Schmidhuber J. Long short-term memory[J]. Neural computation, 1997, 9 (8): 1735-1780.